

UNIVERSIDAD
NACIONAL
DE COLOMBIA

Evaluación de descriptores para la detección del defecto de decolorado en granos verdes de café de la variedad Castilla usando técnicas de visión por computador


Alberto M. Ceballos-Arroyo, John W. Branch-Bedoya

Departamento de Ciencias de la Computación y de la Decisión, Grupo de I+D en Inteligencia Artificial, Universidad Nacional de Colombia, Medellín, Colombia

* E-mails: alceballosa@unal.edu.co, jwbranch@unal.edu.co

Importancia del café en Colombia

El café es uno de los productos de exportación y consumo interno más importantes para la economía colombiana. Entre octubre de 2016 y enero de 2017 se exportaron más de 5.1 millones de sacos de café, por lo que el control de su calidad es un punto clave. Sin embargo, por ser de índole visual, en este se invierten grandes cantidades de recursos y tiempo.



Ejemplos de grano de café sin defectos.

Proceso de control de calidad del café

El proceso de control de calidad consiste de varias etapas. Este trabajo se centra en la selección de los granos de café con defectos, que ocurre cuando el caficultor lleva el saco con los granos a la distribuidora y se hace un muestreo en el que dependiendo de la cantidad de granos con defectos se define la calidad del saco.

El defecto de decolorado

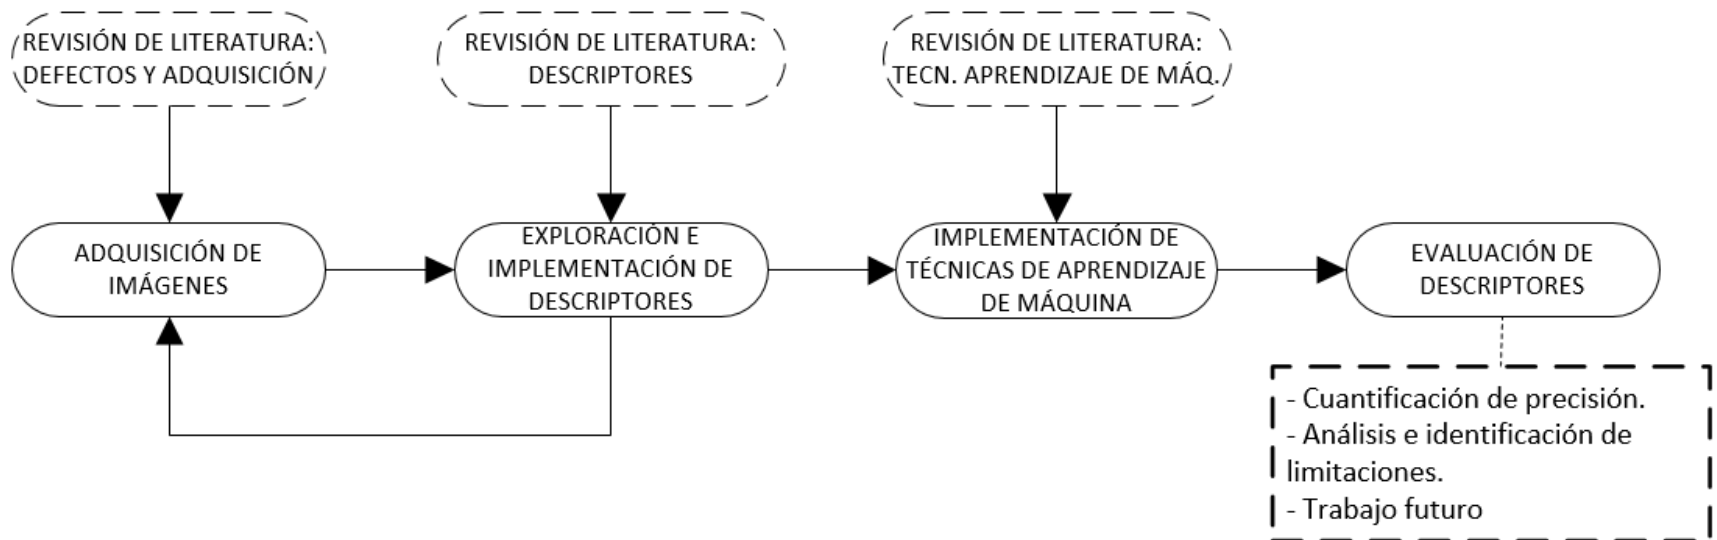
Este defecto se caracteriza por un grano con alteraciones en su color normal, presenta colores que van desde el blanqueado, crema hasta el carmelita.



Granos con el defecto de decolorado. Fuente: FNC.

Metodología propuesta I


Se propone una metodología clásica de extracción de características (descriptores) con el fin de caracterizar los granos de café.



Metodología para detección de defectos.

Metodología propuesta II

Una metodología alternativa es el uso de redes neuronales convolucionales (CNN, por sus siglas en inglés).



Adquisición de los datos


Para la construcción del conjunto de datos se adquirieron muestras de granos verdes de café de la variedad Castilla. Se tomaron fotos utilizando una cámara Canon Rebel T3, con el modo de iluminación por defecto con balanceo de blancos, resolución de 2256x1504, ISO de 200 y exposición de 1/40.



Montaje de adquisición.

Conjunto de datos


Se elaboró con un conjunto de datos conformado por 168 muestras con el defecto de decolorado y 448 granos sanos.



Muestras con el defecto de decolorado.

Extracción de características: descriptores de color (12)

Se extrajeron descriptores de color a partir de los histogramas de las imágenes como la media, que representa el promedio de color del grano, la desviación estándar, que indica qué tan dispersos se encuentran los valores de intensidad, y la kurtosis y asimetría, que dan cuenta del sesgo en la distribución del color.









<https://codeburst.io/2-important-statistics-terms-you-need-to-know-in-data-science-skewness-and-kurtosis-388fef94eeaa>

Extracción de características: descriptores de forma (9)

Se evaluaron como descriptores de forma los 7 momentos de Hu, que han sido utilizados ampliamente en la literatura para describir la forma de objetos de manera invariante a la rotación y la escala.


Se evaluaron asimismo 2 descriptores de asimetría respecto al eje principal del grano.

id	Image	H[0]	H[1]	H[2]	H[3]	H[4]	H[5]	H[6]
K0		2.78871	6.50638	9.44249	9.84018	-19.593	-13.1205	19.6797
S0		2.67431	5.77446	9.90311	11.0016	-21.4722	-14.1102	22.0012
S1		2.67431	5.77446	9.90311	11.0016	-21.4722	-14.1102	22.0012
S2		2.65884	5.7358	9.66822	10.7427	-20.9914	-13.8694	21.3202
S3		2.66083	5.745	9.80616	10.8859	-21.2468	-13.9653	21.8214
S4		2.66083	5.745	9.80616	10.8859	-21.2468	-13.9653	-21.8214

<https://www.learnopencv.com/shape-matching-using-hu-moments-c-python/>

Extracción de características: descriptores de textura (12)

Estos descriptores se basan en la matriz coocurrencia de niveles de gris, que define la frecuencia de la ocurrencia de duplas de valores de gris específicos a ciertas distancias (por ejemplo, blanco - 255- a la derecha o a la izquierda de negro -0-) y permite hacer un análisis generalizado de la textura de a partir de estadísticos como el contraste, la correlación, la energía y la homogeneidad.



Khan, M. N., Machine and Deep Learning Techniques for Real-Time In-Vehicle Fog Detection and Speed Behavior Investigation Utilizing the SHRP2 Naturalistic Driving Study Data, PhD thesis (05 2018). 6

Configuraciones de los descriptores

Para validar la relevancia de cada conjunto de descriptores se propuso evaluar la fase de clasificación con las siguientes configuraciones:


- Solo descriptores de color.
- Solo descriptores de forma.
- Descriptores de color, forma y textura.
- Descriptores de color y textura.

Clasificación

- Se usó validación cruzada (90/10).
- Se reporta exactitud, sensibilidad, especificidad y puntaje F1 promedio.

Se emplearon tres clasificadores:

- **Regresión logística.**
- Máquina de soporte vectorial.
- CNN de 4 capas.




Clasificación

- Se usó validación cruzada (90/10).
- Se reporta exactitud, sensibilidad, especificidad y puntaje F1 promedio.

Se emplearon tres clasificadores:

- Regresión logística.
- **Máquina de soporte vectorial.**
- CNN de 4 capas.

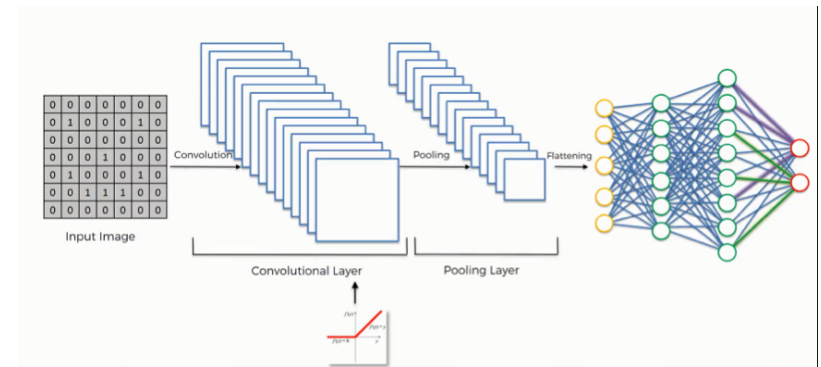


Clasificación

- Se usó validación cruzada (90/10).
- Se reporta exactitud, sensibilidad, especificidad y puntaje F1 promedio.

Se emplearon tres clasificadores:

- Regresión logística.
- Máquina de soporte vectorial.
- **CNN de 4 capas.**



<https://www.superdatascience.com/blogs/convolutional-neural-networks-cnn-summary/>

Red Convolutacional

- La red propuesta consta de 3 capas convolucionales y una capa completamente conectada con normalización por lotes.
- Se utilizó un generador de imágenes rotadas para garantizar invariabilidad ante las rotaciones.

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 252, 252, 64)	4864
batch_normalization (Batch Normalization)	(None, 252, 252, 64)	256
re_lu (ReLU)	(None, 252, 252, 64)	0
max_pooling2d (MaxPooling2D)	(None, 84, 84, 64)	0
conv2d_1 (Conv2D)	(None, 82, 82, 64)	36928
batch_normalization_1 (Batch Normalization)	(None, 82, 82, 64)	256
re_lu_1 (ReLU)	(None, 82, 82, 64)	0
max_pooling2d_1 (MaxPooling2D)	(None, 27, 27, 64)	0
conv2d_2 (Conv2D)	(None, 25, 25, 64)	36928
batch_normalization_2 (Batch Normalization)	(None, 25, 25, 64)	256
re_lu_2 (ReLU)	(None, 25, 25, 64)	0
max_pooling2d_2 (MaxPooling2D)	(None, 8, 8, 64)	0
flatten (Flatten)	(None, 4096)	0
dense (Dense)	(None, 256)	1048832
batch_normalization_3 (Batch Normalization)	(None, 256)	1024
re_lu_3 (ReLU)	(None, 256)	0
dense_1 (Dense)	(None, 2)	514
Total params: 1,129,858		
Trainable params: 1,128,962		
Non-trainable params: 896		

Resultados

Clasificador	Conjunto de Descriptores	Exactitud	Sensibilidad	Especificidad	Puntaje-F1
Regresión Logística	Solo forma	0.52	0.53	0.51	0.52
	Solo color	0.68	0.72	0.69	0.72
	Color y textura	0.81	0.74	0.84	0.80
	Forma, color y textura	0.76	0.77	0.75	0.76
SVM	Solo forma	0.55	0.56	0.55	0.55
	Solo color	0.76	0.72	0.85	0.79
	Color y textura	0.87	0.84	0.91	0.88
	Forma, color y textura	0.86	0.84	0.90	0.86
CNN de 4 capas	-	0.94	0.92	1.00	0.94

Cuadro 1: Resultados de clasificación. Se probaron distintas combinaciones de los descriptores planteados con los clasificadores regresión logística y máquina de soporte vectorial. Se probó asimismo una arquitectura de red neuronal convolucional de 4 capas la cual se ejecutó directamente sobre las imágenes sin necesidad de una extracción de características previa.

Conclusiones

Como se pudo observar en los resultados, los descriptores de forma tienen un aporte limitado en comparación con los descriptores de color y textura, que resultan en una clasificación aceptable de los granos. Esto tiene sentido al evaluar individualmente los granos, pues en general el defecto de decolorado no viene acompañado de deformaciones del grano.

En cualquier caso, métodos como la regresión logística y las máquinas de soporte vectorial obtuvieron un desempeño inferior al de redes neuronales convolucionales de tamaño mediano, con las que se logra una exactitud del 94%.

Trabajo futuro

En futuros trabajos se propone hacer una evaluación de una mayor variedad de arquitecturas de red neuronal convolucional y utilizar la totalidad del conjunto de datos elaborado, considerando no solo las imágenes de granos sanos y con el defecto decolorado, sino también las del resto de defectos.

En este sentido, será necesario evaluar enfoques de aumentación sintética de datos pues para algunas clases el número de muestras es muy reducido, pero se considera que el potencial de las arquitecturas convolucionales puede resultar en una clasificación muy precisa con un número elevado de clases.


Referencias

- Federacion Nacional de Cafeteros, “Producción de café de Colombia aumenta 12 % en enero,” (2017). **1**
- Parque del café, “Fases de Cultivo o Procesos del Café,” (2000). **1**
- Atencio, P., Sánchez T, G., and Branch, J. W., “Automatic visual model for classification and measurement of quality of fruit: Case mangifera indica L,” *DYNA* **76(160)**, 317–326 (2009). **1**
- Federación Nacional de Cafeteros and Federacion Nacional de Cafeteros, “Clasificaciones de calidad,” (2010). **1, 2**
- Specialty Coffee Association, [*Arabica Green Coffee Defect Handbook 2018*], 3 ed. (2018). **1**
- Calvini, R., Ulrici, A., and Amigo, J. M., “Practical comparison of sparse methods for classification of Arabica and Robusta coffee species using near infrared hyperspectral imaging,” *Chemom. Intell. Lab. Syst.* **146**, 503–511 (2015). **1, 2**
- Portugal-Zambrano, C., Gutierrez-Caceres, J., Ramirez-Ticona, J., and Beltran-Castanon, C., “Computer vision grading system for physical quality evaluation of green coffee beans,” *Proc. 2016 42nd Lat. Am. Comput. Conf. CLEI 2016* (2017). **1**
- Sandoval, Z. and Prieto, F., “Procesamiento de imágenes para la clasificación de café cereza,” (2016). **2**
- Ramos, P., Sans, J., and Oliveros, C., “Identificación y clasificación de frutos de café en tiempo real a través de la medición de color,” *Rev. Cenicafé* **61(4)**, 315–326 (2014). **2**
- De Oliveira, E. M., Leme, D. S., Barbosa, B. H. G., Rodarte, M. P., and Alvarenga Pereira, R. G. F., “A computer vision system for coffee beans classification based on computational intelligence techniques,” *J. Food Eng.* **171**, 22–27 (2016). **2**

Agradecimientos

Se agradece a MINCIENCIAS (anteriormente COLCIENCIAS) por financiar esta investigación a través de la Convocatoria de Becas-Pasantías Jóvenes Investigadores e Innovadores 812 - 2018 y a la Vicedecanatura de Investigación y Extensión de la Facultad de Minas por su apoyo administrativo en la ejecución del proyecto. Se agradece igualmente al profesor Albeiro Espinosa Bedoya del Grupo de Investigación y Desarrollo en Inteligencia Artificial por su apoyo en la obtención de los granos verdes de café y a Camila Carmona por su apoyo en la adquisición de las imágenes.

¿Preguntas?



UNIVERSIDAD
NACIONAL
DE COLOMBIA